



Waypoint: Detecção Adaptativa de Pontos de Mudança em Séries Temporais

*Anthony Viegas Heimlich · Gabriel Alves Giuliano · Renato
Mauro · Antonio Castro Filho · Helga Balbi · Rafaelli
Coutinho · Janio de Souza Lima · Eduardo Ogasawara*

Motivação

Não Estacionariedade

Séries de sistemas de controle mudam de regime ao longo do tempo, tornando modelos estáticos inadequados.

Ruído e Oscilações

Variações locais dificultam a decisão e aumentam a taxa de alarmes falsos.

Eventos Críticos

Mudanças persistentes podem indicar falhas, intervenções ou degradação em poços de petróleo e gás.

Custo Operacional

Alarmes falsos têm custo elevado em ambientes industriais de alto risco como produção de óleo e gás.

Revisão da Literatura

Métodos Clássicos

CUSUM e GLR são interpretáveis, mas frágeis em sinais ruidosos e não lineares. Assumem distribuições simples e falham em séries multivariadas complexas.

Autoencoders Isolados

Modelam padrões complexos, mas deslocam toda a robustez para a arquitetura neural, sem mecanismo explícito de decisão estatística.

Definição do Problema

Falta articulação explícita entre representação, decisão estatística e adaptação nos métodos existentes.

Lacuna Identificada

- Métodos clássicos não se adaptam a mudanças de regime.
- Autoencoders isolados carecem de mecanismo explícito de decisão.
- Nenhuma abordagem combina representação neural com supervisão estatística rigorosa.

Requisitos do Problema

- Detectar mudanças persistentes, não flutuações locais.
- Retreinar somente após mudança confirmada estatisticamente.
- Manter confiabilidade operacional com baixa taxa de falsos positivos.

Waypoint

Uma abordagem adaptativa que combina representação neural e supervisão estatística para detectar mudanças de regime em séries temporais com alta confiabilidade operacional. O método é estruturado em três etapas, detalhadas a seguir.

Etapa 1 • Autoencoder

Aprende o regime normal sem supervisão, capturando a estrutura latente da série.

Etapa 1 • Erro de Reconstrução

O erro de reconstrução vira sinal escalar de desvio em relação ao regime aprendido.

Etapa 2 • Normalização

O resíduo é padronizado via Z-score, tornando a decisão invariante à escala do sensor.

Etapa 3 • CUSUM Bilateral

Supervisiona os resíduos normalizados, acumulando desvios positivos e negativos.

Etapa 3 • Cross-Tc

Confirma a mudança antes de retreinar, evitando adaptações espúrias.

Algoritmo Proposto

Entrada: Série temporal $\{x_t\}_{t=1}^T$, janela w , valor de referência k , limiares h_{low} , h_{high} , **warmup**, tamanho de retreinamento r

O algoritmo implementa as três etapas do Waypoint de forma sequencial e adaptativa.

1. Treinar o autoencoder com janelas **do** regime de referência; // Etapa 1
2. para cada janela observada no instante t faça
3. reconstruir a janela e calcular o erro E_t ; // Etapa 1
4. normalizar o resíduo e obter Z_t ; // Etapa 2
5. atualizar $S+_t \leftarrow \max(0, S+_{t-1} + Z_t - k)$; // Etapa 3
6. atualizar $S-_t \leftarrow \min(0, S-_{t-1} + Z_t + k)$; // Etapa 3
7. se $S+_t > h_{\text{low}}$ ou $S-_t < -h_{\text{low}}$ então // Etapa 3
8. abrir ou atualizar alarme preliminar;
9. se o alarme preliminar contiver uma ultrapassagem de h_{high} então
10. confirmar mudança de regime; // Etapa 3
11. suspender alertas por **warmup** amostras;
12. retreinar o autoencoder com as últimas r amostras; // Etapa 3
13. atualizar as estatísticas de referência e reinicializar o CUSUM;

O retreinamento não é periódico nem manual: ele é governado pelo supervisor estatístico acoplado à série de resíduos.

Etapa 1 – Representação por Autoencoder

Organização em Janelas

A série multivariada é segmentada em janelas de tamanho w . O autoencoder comprime cada janela em espaço latente $L < w$, capturando a estrutura essencial do regime.

Interpretação

O erro aumenta quando a janela atual deixa de se assemelhar ao regime aprendido. O quantil empírico auxilia a leitura do regime de referência.

Fórmula do Erro Quadrático Médio

$$E_t = \frac{1}{w} \sum_{i=1}^w (x_{t,i} - \hat{x}_{t,i})^2$$

Onde x é a entrada original e $\hat{x}$ é a reconstrução do autoencoder para cada amostra i da janela no instante t .

Etapa 2 – Normalização dos Resíduos

Fórmula do Z-score

$$Z_t = \frac{E_t - \mu_t^{buf}}{\sigma_t^{buf} + \epsilon}$$

O Z-score usa um buffer recente de monitoramento para estimar média e desvio padrão locais, tornando a decisão invariante à escala do sensor.

Por que Padronizar?

A decisão precisa ser **invariante à escala do sensor**, permitindo comparabilidade entre diferentes variáveis monitoradas simultaneamente.

Reinicialização Adaptativa

Após mudança confirmada, as estatísticas do buffer são reinicializadas e o limiar auxiliar é reestimado no novo regime, garantindo adaptação contínua.

Etapa 3 – Decisão e Retreinamento

Lógica de **dois limiares**: sensibilidade inicial com **h_low** e confirmação conservadora com **h_high**.

CUSUM Bilateral

$$S_t^+ = \max(0, S_{t-1}^+ + Z_t - k)$$

$$S_t^- = \min(0, S_{t-1}^- + Z_t + k)$$

Acumula desvios positivos e negativos separadamente, com parâmetro de folga k .

Limiar Baixo (**h_low**)

Abre o alarme preliminar quando o acumulador ultrapassa o limiar de sensibilidade, sinalizando possível mudança de regime.

Limiar Alto (**h_high**) + Cross-Tc

Confirma a mudança somente quando o sinal persiste acima do limiar conservador. O Cross-Tc reduz confirmações espúrias causadas por picos transitórios.

Configuração Experimental



3W Dataset

Dataset com eventos reais indesejáveis raros em poços de petróleo, representativo de cenários operacionais críticos.



Instâncias Tipo 1

Avaliação conduzida em instâncias Tipo 1 para dois poços distintos, com recorte representativo do problema.



Quatro Sensores

P-TPT, T-TPT, P-MON-CKP e T-JUS-CKP por poço. Avaliação conduzida individualmente por sensor.

Parâmetros e Método de Referência

Parâmetros do Waypoint

Janela: **$w = 12$** · Espaço latente: **$L = 4$**

Treinamento inicial: **40 épocas** · Retreinamento: **20 épocas**

Supervisor: **$k = 0,35$** · **$h_{low} = 3,5$** · **$h_{high} = 6$**

Parâmetros calibrados empiricamente no recorte experimental.

Linha de Base: GLR

O método **Generalized Likelihood Ratio (GLR)** foi utilizado como comparador estatístico clássico, permitindo avaliar o ganho do Waypoint em precisão e confiabilidade operacional.

 O GLR é interpretável e amplamente usado, mas sensível a ruído — exatamente a limitação que o Waypoint busca superar.

Protocolo de Avaliação

Precisão

Proporção de alarmes que correspondem a eventos reais. Priorizada na análise por refletir a **confiabilidade operacional** do sistema.

Revocação

Proporção de eventos reais detectados. Usada como contrapeso da sensibilidade, não como métrica principal.

F1-Score

Resume o compromisso entre precisão e revocação em um único valor balanceado.

Avaliação Soft (SoftED)

Tolerância temporal **$\delta = 250$ amostras**. Rótulos de evento expandidos em vizinhança local de 25 amostras. Detecções vizinhas ao evento são operacionalmente úteis *[Salles et al., 2024]*.

⚠ O problema é severamente desbalanceado — a leitura dos resultados prioriza **precisão, revocação e utilidade temporal da detecção**.

Resultados Quantitativos

Tabela 1 — Resultados por sensor nos Poços 1 e 2 (Precisão / Revocação / Precisão soft / Revocação soft)

Sensor	Método	Poço 1 Prec.	Poço 1 Rev.	Poço 1 P. soft	Poço 1 R. soft	Poço 2 Prec.	Poço 2 Rev.	Poço 2 P. soft	Poço 2 R. soft
P-TPT	GLR	0,011	0,941	0,009	<u>1,000</u>	0,007	0,500	<u>0,011</u>	1,000
P-TPT	AE + Cross-Tc	0,031	0,010	0,010	<u>1,000</u>	0,000	0,000	0,009	0,755
T-TPT	GLR	0,005	0,500	0,008	<u>1,000</u>	0,008	1,000	<u>0,011</u>	<u>1,000</u>
T-TPT	AE + Cross-Tc	0,000	0,000	0,009	<u>1,000</u>	0,026	0,010	<u>0,011</u>	<u>1,000</u>
P-MON-CKP	GLR	0,009	0,990	0,008	<u>1,000</u>	0,007	0,500	<u>0,010</u>	<u>1,000</u>
P-MON-CKP	AE + Cross-Tc	0,026	0,010	0,009	<u>1,000</u>	0,000	0,000	<u>0,010</u>	<u>1,000</u>
T-JUS-CKP	GLR	0,009	1,000	0,008	1,000	0,008	1,000	0,000	0,000
T-JUS-CKP	AE + Cross-Tc	0,026	0,010	0,009	1,000	0,026	0,010	0,000	0,000

Na avaliação pontual, o GLR privilegia revocação mas com precisão muito baixa. O Waypoint é mais conservador: precisão superior em 5 dos 8 casos. No sensor P-TPT do Poço 1, o GLR produziu **8.773 falsos positivos** contra apenas **31 do Waypoint** — redução de 99,6%.

Análise Qualitativa




Figura 1. Comparação qualitativa entre o Waypoint e o GLR. (a) Série temporal com CUSUM, alarmes de alto limiar (vermelho), baixo limiar (laranja) e anomalias reais (azul). (b) Erro normalizado (Z-score) com limiares de decisão. (c) Detecção baseada no método GLR.

O Waypoint adapta o modelo após mudanças confirmadas, evitando a cascata de alarmes espúrios. O GLR tende a permanecer acima do limiar por longos períodos, deslocando o detector para um estado de alarme praticamente contínuo.

Discussão

O que o Waypoint entrega

- O autoencoder produz resíduos sensíveis a desvios estruturais.
- O supervisor estatístico filtra flutuações locais e restringe a confirmação a desvios persistentes.
- O retreinamento evita que o sistema permaneça saturado no novo regime.
- Menor agressividade ponto a ponto → alarmes mais confiáveis após mudanças de regime.

Limitações e Trade-offs

- Quando a revocação pontual zera, o supervisor confirma a mudança com atraso (latência de alarme, não ausência de detecção).
- Sob avaliação soft, o desempenho é competitivo — reforçando que a perda é de latência, não de cobertura.
- Validação restrita a um recorte do 3W Dataset (instâncias Tipo 1, dois poços, quatro sensores).
- Parâmetros (k , h_{low} , h_{high}) calibrados empiricamente no recorte avaliado.

Conclusão

O Waypoint combina **autoencoder**, **CUSUM bilateral** e **Cross-Tc** em um protocolo adaptativo com separação clara de responsabilidades: o modelo neural representa; o supervisor estatístico decide.

Principal Ganho

Confiabilidade operacional dos alarmes com redução drástica de falsos positivos.

Contribuição Metodológica

Retreinamento controlado por confirmação estatística, não por heurísticas arbitrárias.

Trabalhos Futuros

Ampliar para mais tipos de falha, variáveis e domínios além do 3W Dataset. Avaliar sensibilidade dos parâmetros k , h_{low} e h_{high} em outros contextos.



Agradecimentos



*Anthony Viegas Heimlich · Gabriel Alves Giuliano · Renato Mauro · Antonio Castro Filho ·
Helga Balbi · Rafaelli Coutinho · Janio de Souza Lima · Eduardo Ogasawara*

<https://eic.cefet-rj.br/dal>

