



## **WARMA: Window-Based Autoregressive Moving Average**

*Arthur Ronald Garcia · Jorge Soares · Laura Assis · Fabio  
Porto · Dayse Pastore · Eduardo Ogasawara*

# Introdução

Previsão de séries temporais é uma tarefa central em diversas áreas, e modelos lineares clássicos como AR, MA, ARMA e ARIMA são amplamente utilizados para isso. Porém, esses modelos dependem de premissas que frequentemente não se sustentam na prática.

## Premissa Violada

Esses modelos assumem covariância-estacionariedade — média, variância e covariância constantes ao longo do tempo. Séries econômico-financeiras reais raramente satisfazem essa condição sem transformação prévia.

## Transformações Globais

A abordagem mais comum é a diferenciação global (ARIMA). O problema: ela age sobre toda a série de uma vez, mesmo quando a não-estacionariedade é apenas local.

## Estrutura Local Oculta

Embora a série completa seja não-estacionária, subsequências locais frequentemente se comportam de forma estável. Modelar essas subsequências preserva a interpretabilidade e evita distorções desnecessárias do sinal original.

# Problema e Questão de Pesquisa

Transformações globais como a diferenciação atuam sobre toda a série de uma vez, mesmo quando a não-estacionariedade é impulsionada principalmente por mudanças locais de nível ou escala. Com isso, parte da estrutura original torna-se menos interpretável, dificultando a análise e o diagnóstico.

## Questão de Pesquisa

Um esquema de pré-processamento local baseado em janelas consegue produzir representações com ordem de integração zero, preservando a interpretabilidade e mantendo desempenho preditivo competitivo com o ARIMA?

# O Modelo WARMA

## O Problema Global

A série completa pode ser não estacionária — mas isso não significa que cada subsequência local também o seja. Transformações globais tratam toda a série de forma uniforme, ignorando variações locais.

## A Solução Local

Subsequências locais podem ser aproximadamente estáveis. O WARMA usa janelas deslizantes para estimar propriedades locais e, em seguida, ajusta um modelo ARMA após a estacionarização local — uma mudança fundamental na unidade de pré-processamento.

## Pipeline WARMA



### Sequenciamento

Janela deslizante extrai subsequências locais da série temporal original.



### Normalização da Média

Remove a tendência local subtraindo a média de cada janela.



### Remoção de Outliers

Identifica e trata valores atípicos dentro de cada subsequência local.




### Normalização da Variância

Estabiliza a escala dividindo pelo desvio padrão local de cada janela.



### Modelagem (ARMA)

Ajuste do modelo ARMA sobre as subsequências localmente estacionarizadas.



# Sequenciamento por Janelas Deslizantes

## Definição Formal

Dada a série  $\mathbf{X} = \langle \mathbf{x}_1, \dots, \mathbf{x}_n \rangle$ , com restrições  $3 \leq \mathbf{w} \leq \mathbf{n}$  e  $1 < \tau \leq \mathbf{w}$ , o tamanho de janela  $\mathbf{w}$  e o deslocamento  $\tau$  definem as subsequências. São geradas  $\mathbf{h}$  janelas alinhadas ao final da série, armazenadas na matriz  $\mathbf{A} \in \mathbb{R}^{(\mathbf{h} \times \mathbf{w})}$  (uma subsequência por linha).

- $\mathbf{h} = \lfloor (\mathbf{n} - \mathbf{w}) / \tau \rfloor + 1$
- $\mathbf{o} = (\mathbf{n} - \mathbf{w}) \bmod \tau$
- $\text{seq}_{i, \mathbf{w}, \tau}(\mathbf{X}) = \langle x_{1+\mathbf{o}+(i-1)\tau}, \dots, x_{\mathbf{w}+\mathbf{o}+(i-1)\tau} \rangle$

❏ O offset  $\mathbf{o}$  alinha o janelamento com o final da série — até  $\mathbf{o}$  observações iniciais podem ser excluídas.

## Interpretação dos Parâmetros

### $\mathbf{w}$

Define a escala local da janela — a granularidade em que propriedades locais (média e variância) são estimadas.

### $\tau$

Controla a densidade de amostragem ao longo do tempo. Valores pequenos de  $\tau$  aumentam a continuidade entre janelas adjacentes;  $\tau = \mathbf{w}$  produz janelas sem sobreposição.

# Passo 1: Normalização da Média

## Centralização por Janela

Cada janela é centralizada pela sua média local. Uma etapa sugere predominância de média não constante.

**Fórmula:**  $b_{ij} = a_{ij} - \mu(a_i)$ , onde  $\mu(v) = (1/|v|) \sum_j v_j$

Após essa etapa, janelas discrepantes podem ser opcionalmente descartadas por um critério de **amplitude interquartílica (IQR)**, conforme a técnica de Normalização Adaptativa (Ogasawara et al., 2010). Nos experimentos, essa filtragem permanece inativa para manter a comparação com o ARIMA metodologicamente mais rigorosa.

## Conexão Interpretativa

---

Corrige **mudanças de nível** locais

---

Trata **tendências determinísticas** locais

---

Captura também padrões de **passeio aleatório** localmente

---

Preserva a **interpretabilidade** da correção

# Passo 2: Normalização da Variância

## Estabilização de Escala

Se a estacionariedade não é atingida após a Etapa 1, a variância é estabilizada. Duas etapas indicam necessidade de tratar a escala local. Linhas com variância zero são mapeadas para zero.

**Fórmula:**  $c_{ij} = b_{ij} / \sigma(b_i)$

## Valor Interpretativo

O número de etapas indica qual propriedade local precisou de tratamento:

- **s = 1** → correção de nível
- **s = 2** → correção de nível e escala

O modelo distingue explicitamente correções de nível e escala.

# Representação Compacta e Modelagem ARMA

01

## Retenção das Últimas Colunas

A série usada para modelagem é **Vec(D1:h, (w-τ+1):w)**, a vetorização da submatriz formada pelas últimas τ colunas de cada linha. Isso evita o reuso excessivo de observações sobrepostas.

02

## Modelagem ARMA

A série estacionária resultante  $y_t$  é modelada com ARMA:  $\varphi(B)y_t = \theta(B)\epsilon_t$ , onde  $\varphi(B)$  e  $\theta(B)$  são os polinômios autorregressivo e de médias móveis no operador de defasagem. Notação completa: **WARMA(p,(w,s,τ),q)**.

03

## Fórmula Compacta

Seja  $s \in \{0,1,2\}$  o número de etapas. Para cada observação  $x_t$ , a representação estacionária é:

$$y_t = (x_t - f\mu(s) \cdot \mu(ag(t))) / (\sigma(ag(t)))f\sigma(s)$$

onde  $g(t)$  indica a janela associada a  $x_t$ ,  $f\mu(s) = 0$  se  $s=0$  e 1 caso contrário,  $f\sigma(s) = 1$  se  $s=2$  e 0 caso contrário. Isso cobre três casos: **(i)** já estacionária ( $s=0$ ); **(ii)** normalização de média apenas ( $s=1$ ); **(iii)** normalização de média e variância ( $s=2$ ).

- ❑ s é definido como o menor número de etapas para o qual a série transformada possui ordem de integração zero, segundo a função `ndiffs` (pacote *forecast*, Hyndman & Khandakar, 2008).

# Algoritmo de Seleção do Modelo WARMA

A seleção do modelo WARMA segue uma busca exaustiva sobre os hiperparâmetros ( $w$ ,  $\tau$ ), avaliando para cada combinação a série pré-processada e selecionando o modelo com menor AICc.

Input: série temporal  $X$ , window.length máximo

Output: modelo ARMA otimizado

AICc.model  $\leftarrow \infty$

ARMA.model  $\leftarrow \text{NULL}$

para  $w \in \{3, \dots, \text{window.length}\}$ ,  $\tau \in \{1, \dots, w\}$  faça

$s \leftarrow$  menor valor em  $\{0, 1, 2\}$  tal que  $\text{ndiffs}(\text{warma.preprocessing}(X, w, \tau, s)) = 0$

$Y \leftarrow \text{warma.preprocessing}(X, w, \tau, s)$

    obj  $\leftarrow \text{auto.arima}(Y)$

    se  $\text{AICc}(\text{obj}) < \text{AICc.model}$  então

        AICc.model  $\leftarrow \text{AICc}(\text{obj})$

        ARMA.model  $\leftarrow \text{ARMA}(\text{obj})$

    fim

fim

retorne ARMA.model

# Avaliação Experimental

---

## Séries Sintéticas

Mudanças de nível, tendências determinísticas e passeios aleatórios — para validação controlada da hipótese de etapas. A busca avalia exaustivamente combinações de  $(w, \tau)$ , com  $w$  iniciando em 3 e  $\tau$  variando de 2 até  $w$ .

## Dados Reais

80 séries mensais econômico-financeiras não estacionárias, cobrindo 7 domínios: juros, dívida líquida do setor público (DLSP), atividade econômica, ações, câmbio, IPCA e commodities. Seleccionadas de um conjunto amplo de 92 séries provenientes de B3, Investing.com, Banco Central do Brasil, IBGE e Ipeadata. Séries estacionárias foram excluídas.

# Hipótese Conceitual dos Passos: Evidências


## Séries Sintéticas

- Mudanças de nível, tendências determinísticas e passeio aleatório analisado atingem **ordem de integração zero em uma única etapa** ( $s=1$ )
- A representação baseada em janelas captura localmente padrões que o operador de diferença global tende a obscurecer

## Séries Reais (80 séries)

- Todas as 80 séries atingem estacionariedade em **no máximo duas etapas**
- **82,5%** das séries atingem estacionariedade em **uma etapa** ( $s=1$ ) — correção de nível suficiente
-  **17,5%** requerem **duas etapas** ( $s=2$ ) — correção de nível e escala; concentrados em **commodities, atividade econômica e mercado acionário**

⚠ As ordens de integração 1 e 2 **não correspondem diretamente** a 1 ou 2 etapas WARMA — elas capturam informações complementares sobre não-estacionariedade. Séries com ordem de integração 2 aparecem apenas na dívida líquida do setor público (DLSP), ao passo que casos de duas etapas WARMA ocorrem também em outros domínios.



# Análise dos Hiperparâmetros

Os hiperparâmetros selecionados revelam como a não estacionariedade se manifesta localmente nas séries analisadas.

## Janelas Curtas


Modelos concentram-se em janelas curtas, especialmente  **$w = 3$** , indicando não estacionariedade de escala local muito pequena.

## Deslocamento $\tau$ Pequeno

$\tau$  aparece frequentemente em valores pequenos admissíveis, especialmente **2 e 3**, controlando sobreposição entre janelas.

## Concentração Secundária

Uma concentração menor ocorre em torno de  **$w = 12$  a  $14$** , sugerindo sazonalidade mensal em algumas séries.




# Desempenho Preditivo: WARMA vs. ARIMA

O MASE agregado é próximo entre WARMA e ARIMA, demonstrando competitividade do modelo proposto com diferenças por domínio.

| Método | Período | Interest    | NPSD        | Econ. act.  | Stocks      | Exchange | CPI  | Commod. |
|--------|---------|-------------|-------------|-------------|-------------|----------|------|---------|
| ARIMA  | 1-3     | 0.99        | 2.85        | 1.93        | 3.92        | 3.37     | 1.30 | 1.95    |
| ARIMA  | 1-12    | 2.84        | 5.73        | 1.79        | 5.10        | 3.35     | 1.52 | 5.86    |
| WARMA  | 1-3     | <b>0.63</b> | <b>2.66</b> | <b>1.37</b> | <b>3.26</b> | 3.45     | 1.50 | 2.39    |
| WARMA  | 1-12    | <b>2.27</b> | <b>4.57</b> | 1.77        | 5.87        | 3.50     | 1.64 | 6.22    |

O WARMA supera o ARIMA para taxas de juros e NPSD em ambos os horizontes, e para atividade econômica e ações no horizonte curto. O ARIMA é superior para câmbio, CPI e commodities. MASE agregado: horizonte 1-3 (ARIMA 2.40, WARMA 2.39), horizonte 1-12 (ARIMA 4.08, WARMA 4.12), acumulado até 14 passos (ARIMA 4.43, WARMA 4.42).



# Conclusões e Trabalhos Futuros

## Estacionarização Local

O WARMA oferece estacionarização local com interpretação explícita das etapas de correção.

## Interpretabilidade

As etapas identificam explicitamente a correção local necessária: nível, escala ou ambos.

## Desempenho Competitivo

O desempenho permanece competitivo com o ARIMA em todos os horizontes avaliados.

## Trabalhos Futuros

Covariância, sazonalidade, sensibilidade de hiperparâmetros e custo computacional.

- ❏ Use o WARMA quando a interpretabilidade da não estacionariedade local for tão importante quanto a acurácia de previsão.



## Agradecimentos



*Arthur Ronald Garcia · Jorge Soares · Laura Assis · Fabio Porto · Dayse Pastore · Eduardo Ogasawara*

*<https://eic.cefet-rj.br/dal>*

